

Bilan du projet

Système d'analyse des compétences demandées — Secteur Minier

Sahel Mohamed Reda — Stage TOD, SBU Mining, Groupe OCP

1. Résumé du projet

Ce projet visait à construire, en 4 semaines, un système automatisé capable de collecter des offres d'emploi du secteur minier, d'en extraire les compétences demandées via un modèle de langage (LLM), de les classer dans un référentiel de 4 catégories, et de présenter les résultats dans un tableau de bord interactif — le tout documenté, testé, et reproductible par un tiers.

2. Ce qui a été construit

Composant	Description
Pipeline de collecte	4 collectors (Greenhouse, Workable, Ashby, Rippling) unifiés par une logique commune, anti-doublon validé, cycle de vie des offres (open/closed)
Extraction de compétences	Extraction par LLM sur l'ensemble des offres, classées dans 4 catégories définies, avec détection des compétences hors périmètre (corporate/administratif)
Automatisation	Pipeline planifié via GitHub Actions, secrets gérés de façon sécurisée, exécution vérifiée en conditions réelles
Dashboard	Application Streamlit interactive : filtres (entreprise, localisation, pays, catégorie, conformité), visualisations multiples, export CSV
Documentation	README complet, testé par clonage à froid ; tests automatisés de base (dédoublonnage, parsing JSON)

3. Résultats — ce qui a été trouvé

L'analyse porte sur 271 offres collectées auprès de 5 entreprises du secteur minier / mining-tech (KoBold Metals, Redwood Materials, American Battery Technology Company, Mariana Minerals, Lilac Solutions), dont environ 251 ont fait l'objet d'une extraction de compétences complète.

Constats principaux

- Project Management est la compétence individuelle la plus demandée, mentionnée dans environ 73% des offres analysées, devant les compétences techniques minières classiques.
- La catégorie Soft & Leadership est présente dans 94,9% des offres, presque à égalité avec Operational & Technical (94,5%) — les compétences comportementales sont quasiment universelles dans cet échantillon.
- Digital & Automation touche 86,5% des offres, confirmant une forte digitalisation du recrutement dans les entreprises étudiées.
- Health, Safety & Risk Management est la catégorie la moins représentée (60,0%), un écart probablement lié à la nature de l'échantillon (entreprises d'exploration/technologie plutôt que d'exploitation traditionnelle).
- Une seule entreprise (Redwood Materials) représente environ 55% du volume total d'offres collectées — un biais de composition majeur à garder en tête pour toute généralisation.

4. Limites du projet

Offres ≠ besoin réel

Les données reflètent ce que les employeurs publient dans leurs offres — pas nécessairement leur besoin réel, leurs priorités de recrutement, ou la difficulté effective à pourvoir ces postes. Une compétence très demandée n'est pas automatiquement une compétence rare ou stratégique.

Aucune mesure de l'offre de compétences

Le projet ne mesure que la demande côté employeurs. Il ne dit rien sur les compétences réellement disponibles chez les candidats. C'est pourquoi le terme "skills gap" (écart offre/demande) est volontairement banni de toute la documentation et du dashboard, remplacé par "compétences demandées dans les offres collectées".

Biais des entreprises sources

L'échantillon de 5 entreprises est mining-tech / exploration, non représentatif du secteur minier traditionnel (exploitants à ciel ouvert, mines souterraines établies). La concentration à 55% sur une seule entreprise accentue ce biais.

Échantillon limité

271 offres sur une fenêtre de quelques semaines ne permettent pas de dégager des tendances temporelles solides ni une couverture géographique large — la majorité des offres se concentre sur 2-3 sites aux États-Unis.

Fiabilité de l'extraction automatique

Les compétences sont extraites par un LLM, avec un prompt affiné itérativement mais jamais validé à 100% manuellement sur l'ensemble du corpus. Un bug significatif (troncature de description tronquant le texte réellement pertinent) a été identifié et corrigé en cours de projet — signe que ce type d'extraction demande une vérification continue, pas une confiance aveugle.

5. Pistes d'amélioration futures

- Élargir l'échantillon à davantage d'entreprises et à des acteurs miniers traditionnels, pour réduire le biais de composition.
- Normaliser plus finement les compétences extraites (au-delà de la casse) pour fusionner les synonymes et formulations proches.
- Croiser avec des données sur l'offre de compétences (ex : bases de CV, données de formation) pour pouvoir, un jour, mesurer un véritable écart offre/demande.
- Étendre la période de collecte pour permettre une vraie analyse de tendance dans le temps.
- Ajouter une validation manuelle systématique sur un échantillon aléatoire à chaque extraction, plutôt que ponctuellement.
- Passer sur une API LLM payante stable pour éliminer les interruptions liées aux limites de débit et aux changements de catalogue des modèles gratuits.

6. Usage de Claude Code

Cette section rend compte, de façon transparente, de ce que l'assistant a bien fait et de ce qui a nécessité une intervention ou une correction manuelle tout au long des 4 semaines.

Ce qui a bien fonctionné

- Mise en place rapide de l'architecture initiale : structure de dossiers, environnement Python, premier connecteur API (Greenhouse), en suivant une méthode progressive jour par jour.
- Généralisation propre du code de collecte pour gérer 4 ATS différents sans duplication, via un module commun (common.py) et une configuration centralisée (sources_config.py).
- Aide au diagnostic méthodique : à chaque bug rencontré (mapping de champs incorrect pour Ashby/Workable/Rippling, troncature de description), la démarche a consisté à vérifier le JSON brut réel plutôt que de supposer la cause — évitant des corrections approximatives.
- Explications pédagogiques détaillées sur demande (fonctionnement du dédoublement SQL, logique de cycle de vie des offres, mécanique des imports Python), utiles pour comprendre le code plutôt que le copier sans le maîtriser.
- Mise en place de l'automatisation GitHub Actions avec gestion sécurisée des secrets, corrigée jusqu'à obtention d'une exécution verte en conditions réelles.
- Construction itérative du dashboard Streamlit, avec une identité visuelle construite intentionnellement plutôt qu'un thème par défaut.

Ce qui a dû être corrigé ou surveillé

- Fiabilité des modèles LLM gratuits : plusieurs migrations ont été nécessaires (Groq -> DeepInfra -> OpenRouter) suite à des limites de débit, des décommissions de modèles, et des changements de catalogue de modèles gratuits — un vrai risque pour un pipeline en production, atténué par une bascule de fournisseur plutôt qu'un abandon.
- Un bug critique de troncature de description (le texte générique "About the Company", répété sur toutes les offres, occupait toute la limite de caractères envoyée au LLM, masquant les vraies responsabilités du poste) n'a été détecté qu'après une vérification manuelle approfondie des résultats — pas lors des premiers tests superficiels. Cela souligne l'importance de vérifier les résultats concrets, pas seulement l'absence d'erreur technique.
- Plusieurs erreurs de copier-coller (code dupliqué dans un même fichier, chemins de fichiers incohérents selon l'emplacement réel du script) ont nécessité des allers-retours de diagnostic, en partie dus à la manipulation manuelle du code entre l'assistant et l'environnement local.
- Le prompt d'extraction a nécessité plusieurs itérations pour éviter que des compétences purement corporate (droit, comptabilité) ne soient classées à tort dans les 4 catégories métier.
- La vérification finale (tests, clonage à froid du dépôt) reste une étape que l'utilisateur a dû exécuter et confirmer lui-même — l'assistant ne peut pas se substituer à cette validation humaine finale.

Bilan de la collaboration

L'assistant a été le plus utile pour accélérer l'écriture de code répétitif, structurer une architecture cohérente, et guider un diagnostic méthodique face à des erreurs. Il a été moins fiable sur les aspects dépendant de services externes changeants (modèles LLM gratuits), et n'a jamais remplacé la nécessité de vérifier concrètement les résultats produits plutôt que de faire confiance à l'absence d'erreur visible.